AI STUDENT COLLECTIVE MADRID

Buscador de Convalidaciones

Reunión 2 · Review de la Semana 1 y plan de la Semana 2

Francisco Jimeno · 100499080@alumnos.uc3m.es

Madrid, 14 de octubre de 2026

SEMANA 1 · RESUMEN

Los tres cimientos están puestos

Las tres tareas de la semana y el setup de los seis están en `main`, con la CI en verde. Hay piloto propuesto y los datos UC3M ya están compartidos.

HECHO

S0 · Repo y setup

- Repo, CI (ruff + pytest), CODEOWNERS y plantilla de PR
- 6/6 setups personales con PR mergeada

HECHO

1A · EDA + candidatas

- Notebook del EDA y CSV grado × universidad
- `candidatas.md` con 6 fichas y recomendación

HECHO

1B · SQLite + scraper UC3M

- Scraper con caché, parser y tests
- 4 cursos en la BD (uno más de lo previsto)

HECHO

1C · Pydantic + web

- Modelos, `ejemplo.json` y bocetos
- Web mínima en Streamlit

14.522
filas en los 3 Excel históricos

2.946
asignaturas UC3M distintas en la BD

9
PRs mergeadas (#13 a #21)

1
piloto propuesto: Georgia Tech

SEMANA 1 · 1A · ALEJANDRA + ÁNGELA

EDA: dónde hay datos y qué nos va a dar problemas

3 XLS oficiales (CCSSJJ 6.943 filas, EPS 6.780, HCD 799) de los cursos 2024-25, 2025-26 y 2026-27. Notebook `01_eda_historical.ipynb` y tabla en `data/processed/`.

¿Dónde hay más datos? (pares deduplicados)

UNIVERSIDAD	PARES
University of California	1.498
Baruch College (CUNY)	460
Purdue University	361
Universidad Torcuato Di Tella	280
Georgia Institute of Technology	**276**
University of Maryland	272

Grados con más pares: Derecho + ADE (1.163), Tecnologías Industriales (893), Estudios Internacionales + Derecho (559).

¿Qué nos va a dar problemas?

PROBLEMA	RECUENTO
Filas eliminadas al deduplicar entre cursos	3.157
Duplicados exactos dentro del mismo curso	1.439
Asignatura UC3M → varias del destino (n:m)	1.896 grupos
Asignatura destino → varias UC3M (n:m)	834 grupos
Filas únicas sin código de destino	304
Universidades escritas de varias formas	1

Además: cabeceras con caracteres rotos (`C�D.`), resueltas renombrando por posición. "University of California" mezcla campus sin identificar.

SEMANA 1 · DECISIÓN

Piloto: Georgia Tech + Ingeniería Biomédica

Criterio acordado: muchos pares, datos limpios y catálogo con descripciones accesibles. Georgia Tech no es la que más pares tiene, pero es la que menos riesgo técnico tiene.

Por qué Georgia Tech

- **276 pares**, todos con código de destino y n:m bajo (32,2 %, el segundo mejor)
- Catálogo único y oficial en **HTML estático**: `catalog.gatech.edu/coursesaz/`
- Título, créditos y descripción de cada curso, en inglés
- Plan B: Purdue (si su catálogo no necesita JavaScript) o Maryland College Park
- Descartadas: UC (campus mezclados, 64 % n:m), Baruch (SPA, 52 % n:m), UTDT (sin catálogo público)

Grados UC3M con más pares en Georgia Tech

GRADO	PARES
Doble Física + Tecnologías Industriales	53
Ingeniería Biomédica	**50**
Ingeniería Física	36
Ingeniería Aeroespacial	26
Ingeniería Informática	21

Propuesta: **Biomédica**. Casi los mismos pares que el doble grado y un único plan, que simplifica el cruce con las fichas UC3M. **A confirmar hoy.**

SEMANA 1 · 1B · FRAN + MERCEDES

Todas las fichas UC3M en SQLite, también las antiguas

Esquema en `docs/esquema_bd.md`; scraper en `src/scrapers/` (cliente, parser y carga). Ejecutarlo dos veces no vuelve a descargar nada.

130
planes de estudio del curso 2026/27

2.737
asignaturas del curso actual (ES + EN)

2.408
con Programa en inglés relleno

4
cursos: 2023/24 a 2026/27 (2.194 a 2.737 asignaturas por curso)

Cómo está hecho

- Enumeración con `findPlanes` y `findAsignaturas`; ficha con `generaFicha` en ES y EN
- Caché en disco y 1,5 s entre peticiones; estado de cada descarga en la tabla `descargas`
- Parser por diccionario de títulos ES/EN, con fixtures y tests que corren en la CI
- Datos compartidos: `python -m src.sync.datos descargar` (Release `uc3m-2026-10-12`)

Adelantado respecto al plan

- Las **fichas antiguas** (tarea de la Semana 3) ya están: cubren los tres cursos de los Excel
- Pendiente menor: 8 de 608 descargas por plan quedaron *parciales*; se relanzan con la caché
- Cerrar la issue #2: la tarea está terminada (PRs #14 y #15)

SEMANA 1 · 1C · HÉCTOR + VÍCTOR

El contrato JSON está cerrado y la web ya lo lee

A partir de aquí la web y el pipeline avanzan en paralelo: nadie cambia el esquema del JSON sin avisar al grupo.

Modelos Pydantic

- `Subject`, `HistoricalMatch`, `Match` y `Resultados`, con un test por clase
- `Match` rechaza un `aviso_ects` que no cuadre con la regla del 25 %
- Cambios en el esquema: `uc3m` → `origen`; nuevos `tipo`, `url` y `grupo` (n:m)

JSON de ejemplo y bocetos

- `public/data/ejemplo.json`: 6 resultados con precedentes, una sugerencia, avisos de ECTS y una n:m
- Bocetos de la pantalla de resultados y del PDF para el tutor
- 10 decisiones de interfaz en `docs/diseno/decisiones_interfaz.md`

Web mínima

- `streamlit run src/ui/app.py`: desplegables de grado y universidad y tabla de resultados
- Estados vacíos y de error (sin JSON o JSON mal formado)
- Tests de la interfaz en la CI

Pendiente (issue #22): el PDF del boceto de resultados está dañado y hay que volver a subirlo como binario · la propuesta PDF tiene que tratar las n:m como una sola fila · la columna "Tipo" muestra la etiqueta, pero en el JSON `tipo` es FB/OB/OP.

CAMBIOS EN EL PLAN

Quitamos la reconciliación de códigos viejos → vigentes

Era el Paso 2 del pipeline (tarea 3A). Con los datos que ya tenemos, no hace falta.

Antes

- Traducir cada código del Excel a su equivalente del plan vigente, en cascada: código → nombre → temario → manual

→

Ahora

- Cada fila del Excel trae código UC3M y curso: se cruza directamente con la ficha de **ese código en ese curso**, que ya está en la BD

Para calibrar

- Se usa el temario del año en que se aprobó el par. Es justo lo que comparó el tutor.

Para la web

- Si el código sigue en el plan vigente, se enseña como precedente. Si no, solo sirve para calibrar.

Efecto en el calendario

- Desaparecen la tarea 3A y la mitad de la 3B: el enlace histórico ↔ destino pasa de la Semana 4 a la 3.

Además: las parejas rotan cada semana. Una persona se queda para mantener el contexto y la otra pasa al equipo siguiente (Datos → Scraping → Web → Datos). **Opcional en la Semana 5:** prototipo de web estática en HTML (Fase 3).

SEMANA 2 · EQUIPOS

Rotación: se queda quien tiene el contexto de la tarea

Cada persona que entra trae algo que su nuevo equipo necesita esta semana.

EQUIPO	SE QUEDA	ENTRA	POR QUÉ
A Datos históricos	**Ángela**	**Héctor** (viene de Web)	Ángela hizo el EDA; Héctor escribió `HistoricalMatch`, el modelo que valida el loader.
B Scraping y matching	**Fran**	**Alejandra** (viene de Datos)	Alejandra revisó el catálogo de Georgia Tech para `candidatas.md`.
C Web	**Víctor**	**Mercedes** (viene de Scraping)	Víctor hizo bocetos y web; Mercedes aporta lógica testeable y ve el final del pipeline.

Semana 3 (siguiendo la rotación)

- Se mueve quien se quedó esta semana: A · Héctor + Víctor · B · Alejandra + Ángela · C · Mercedes + Fran
- Con 3 equipos de 2, cada dos semanas se juntan las parejas de antes, pero en otro equipo

Acciones en el tablero

- Reasignar las issues #4, #5 y #6 a las nuevas parejas
- Actualizar `plan_trabajo.md`: rotación, sin reconciliación y calendario adelantado

SEMANA 2 · TAREAS

Tres tareas independientes

A usa la BD UC3M de la Semana 1, B solo necesita la web de Georgia Tech y C trabaja sobre `ejemplo.json`.

2A · Ángela + Héctor

Histórico en SQLite y cruce con las fichas UC3M

- `src/loaders/historical_xls.py` : leer, validar con `HistoricalMatch`, normalizar y deduplicar
- n:m agrupadas con `grupo` → tabla `historical_matches`
- Columnas nuevas `uc3m_ficha_ok` y `uc3m_vigente`
- **Hecho cuando:** 3 ficheros cargados, test con 10 filas (duplicada, n:m, código que ya no existe) y resumen del piloto

2B · Fran + Alejandra

Catálogo completo de Georgia Tech

- `config/scrapers/gatech.yaml` + `src/scrapers/destination.py` → tabla `dest_subjects`
- Todo el catálogo (~100 páginas estáticas), con caché y pausa
- Factor créditos → ECTS con su fuente documentada
- **Hecho cuando:** catálogo entero en la BD, 10 asignaturas comprobadas a mano y fixtures con tests

2C · Víctor + Mercedes

Web completa y despliegue

- Filtros: etiqueta, score mínimo, tipo y búsqueda
- Checkbox de selección (las n:m van juntas) guardado en `session_state`
- Resumen de ECTS y avisos de ECTS dispares
- **Hecho cuando:** URL pública en Streamlit Community Cloud y tests de la lógica en la CI

PRÓXIMOS PASOS

Qué decidimos hoy y qué tenemos al acabar la semana

Detalle de cada tarea en `docs/plan_trabajo.md` y en las issues del tablero.

Hoy en la reunión

- Confirmar el piloto: **Georgia Tech + Ingeniería Biomédica**
- Confirmar la rotación y reasignar las issues #4, #5 y #6
- Validar que quitamos la reconciliación
- Repartir los pendientes: issue #22 (Víctor), cerrar la #2 y relanzar las 8 descargas parciales (Fran)

Al acabar la Semana 2

TENDREMOS	LO USA EN LA SEMANA 3
`historical_matches` cruzado con UC3M	Enlace con el destino
`dest_subjects` con todo Georgia Tech	Enlace + embeddings
Web pública con datos de ejemplo	PDF con `reportlab`

◆ Hito Semana 3: sabemos cuántos pares de calibración hay (antes estaba en la Semana 4).

Recordatorio: cada tarea en su rama `tarea/<n>-<nombre>`, PR con la CI en verde y revisión de otra persona. Si algo se atasca más de dos días, se cuenta en el grupo.